



Máy Học (Machine Learning)

TS. Đoàn Thanh Nghị

An Giang University

Long Xuyên, Ngày 14 tháng 7 năm 2018

Chương 2 - Đánh giá hiệu năng hệ thống học máy

- 1 Giới thiệu
- 2 Các phương pháp đánh giá
- 3 Các tiêu chí đánh giá
- 4 Lựa chọn mô hình học được

Giới thiệu (1)

- Đánh giá hiệu năng thường được t.hiện dựa trên thực nghiệm (experimentally), hơn là dựa trên phân tích (analytically)
 - Các đánh giá phân tích (analytically evaluation) được sử dụng để chứng minh tính đúng đắn (correct) và tính hoàn chỉnh (complete) của hệ thống (vd: các bộ chứng minh định lý trong Logics)
 - Không thể xây dựng một đặc tả (định nghĩa) hình thức các vấn đề mà hệ thống máy học giải quyết (Đối với bài toán học máy thì tính đúng đắn và tính hoàn chỉnh là gì?)
- Khi thực hiện so sánh hiệu năng của 2 giải thuật học máy, người ta thường thực thi cả 2 giải thuật trên cùng một tập dữ liệu với cùng một nghi thức kiểm tra

Giới thiệu (2)

- Tập trung vào việc đánh giá hiệu năng của hệ thống
 - Thực hiện một cách tự động, sử dụng một tập các ví dụ (tập thử nghiệm)
 - Không cần sự tham gia (can thiệp) của người dùng
- Các phương pháp đánh giá (evaluation methods)
 - Làm sao có được một đánh giá đáng tin cậy về hiệu năng của hệ thống?
- Các tiêu chí đánh giá (evaluation metrics)
 - Làm sao để đo (tính toán) hiệu năng của hệ thống?

Giới thiệu (3)

Table 3. Results on Caltech 101 with 15 training images per class.

Method	Time (s)	Accuracy	Iterations
PmSVM- χ^2	100	72.08%	6 - 9
PmSVM-HI	115	72.18%	6 - 10
LIBLINEAR	77	68.41%	6 - 11
libHIK	167	71.63%	6 - 9
fm- χ^2	224	72.03%	6 - 12
fm-HI	221	71.94%	6 - 10
Graph-matching kernel [6]		75.3 %	
Localized soft-assignment [14]		74.21%	
NBNN+phow kernels [23]		69.2 %	






Figure 2. Training time and accuracy with different p values.



Các phương pháp đánh giá (1)



Các phương pháp đánh giá (2)

- Làm thế nào để thu được một đánh giá đáng tin cậy về hiệu năng của hệ thống?
 - Tập huấn luyện càng lớn thì hiệu năng của hệ thống học càng tốt
 - Tập kiểm thử càng lớn thì việc đánh giá càng chính xác
 - Vấn đề: rất khó có thể xây dựng được tập dữ liệu (rất lớn)
- Hiệu năng của hệ thống không chỉ phụ thuộc vào giải thuật học máy được sử dụng mà còn phụ thuộc vào:
 - Phân bố các lớp (Class distribution)
 - Chi phí của việc phân lớp sai (Cost of misclassification)
 - Kích thước của tập dữ liệu huấn luyện (Size of the training set)
 - Kích thước của tập kiểm thử (Size of the testing set)

Các phương pháp đánh giá (3)

- Hold-out
- Stratified sampling
- Repeated hold-out
- Cross-validation
 - k -fold
 - Leave-one-out
- Bootstrap sampling

Hold-out (Splitting)


- Toàn bộ tập dữ liệu D được chia thành 2 tập con **không giao nhau**
 - Tập huấn luyện D_{train} , để huấn luyện hệ thống
 - Tập kiểm thử D_{test} , để đánh giá hiệu năng của hệ thống đã học
 - $D = D_{train} \cup D_{test}$, thường là $D_{train} \gg D_{test}$
- Yêu cầu
 - Các ví dụ thuộc tập $D_{test} \rightarrow$ không được sử dụng trong quá trình huấn luyện hệ thống
 - Các ví dụ thuộc tập $D_{train} \rightarrow$ không được sử dụng trong quá trình đánh giá hiệu năng của hệ thống
- Các lựa chọn thường gặp: $|D_{train}| = \frac{2}{3}|D|$, $|D_{test}| = \frac{1}{3}|D|$ (các ví dụ được lựa chọn một cách ngẫu nhiên, có thể lặp lại bước này k lần rồi tính giá trị trung bình (Repeated hold-out))
- Phù hợp khi ta có tập dữ liệu đủ lớn

Lấy mẫu phân tầng (Stratified Sampling)

- Đối với các tập dữ liệu có kích thước nhỏ hoặc không cân xứng (imbalanced datasets) → các ví dụ có thể không phải là đại diện
 - Ví dụ: có rất ít các ví dụ đối với một số lớp
- Mục tiêu: Phân bố lớp (class distribution) trong tập huấn luyện và tập kiểm thử phải xấp xỉ như trong tập toàn bộ các ví dụ (D)
- Lấy mẫu phân tầng
 - Là một phương pháp để cân xứng (về phân bố lớp)
 - Đảm bảo tỷ lệ phân bố lớp (tỷ lệ các ví dụ giữa các lớp) trong tập huấn luyện và tập kiểm thử là xấp xỉ nhau
- Phương pháp này không áp dụng cho bài toán học máy dự đoán/hồi quy (vì giá trị đầu ra của hệ thống là giá trị số, không phải nhãn lớp)

Kiểm tra chéo (Cross-validation)

- Để tránh việc trùng lặp ví dụ giữa các tập kiểm thử
- k -fold cross-validation
 - Tập dữ liệu D được chia thành k tập con không giao nhau (gọi là các “fold”), có kích thước xấp xỉ nhau
 - Mỗi lần (trong số k lần) lặp, một tập con được sử dụng như tập kiểm thử (testing data), $k - 1$ tập còn lại là tập huấn luyện (training data) cho hệ thống
 - Giá trị lỗi tổng thể là trung bình cộng của k giá trị lỗi (tương ứng của mỗi *fold*)
 - Thường gặp: $k = 5$ hoặc 10 , phù hợp với tập dữ liệu vừa, nhỏ



Leave-one-out cross-validation

- Là trường hợp đặc biệt của phương pháp Cross-validation
 - Số lượng *fold* bằng kích thước của tập dữ liệu: $k = |D|$
 - Mỗi *fold* chỉ chứa một ví dụ
- Khai thác triệt để tập ví dụ ban đầu
- Không thực hiện bước lấy mẫu ngẫu nhiên (no random-sampling)
- Không phù hợp lấy mẫu phân tầng (vì ở mỗi bước lặp chỉ có một ví dụ trong tập thử nghiệm)
- Chi phí tính toán cao
- Phù hợp với tập dữ liệu D (rất) nhỏ

Bootstrap .632 sampling (1)

- Được đề xuất bởi [Efron & Tibshirani, 1994]
- Phương pháp Cross-validation thực hiện việc lấy mẫu không lặp lại (sampling without replacement)
- Phương pháp Bootstrap sampling thực hiện việc **lấy mẫu có lặp lại (sampling with replacement)** để tạo tập huấn luyện
 - Cho tập dữ liệu D gồm n ví dụ
 - Để tạo tập huấn luyện D_{train} gồm n ví dụ
 - Lấy ngẫu nhiên một ví dụ x từ tập D (tuy nhiên, **không loại bỏ** x khỏi tập D)
 - Đưa ví dụ x vào tập huấn luyện: $D_{train} = D_{train} \cup x$
 - Lặp lại 2 bước trên n lần
 - Sử dụng tất cả các ví dụ thuộc D nhưng không thuộc D_{train} làm tập thử nghiệm: $D_{test} = \{z \in D; z \notin D_{train}\}$

Bootstrap .632 sampling (2)

- Trong mỗi bước lặp, một ví dụ có xác suất $1 - \frac{1}{n}$ để không được lựa chọn để đưa vào tập học
- Vì vậy, xác suất để một ví dụ (sau quá trình lấy mẫu lặp lại - bootstrap sampling) được đưa vào tập kiểm thử là:

$$\langle 1 - \frac{1}{n} \rangle^n \approx e^{-1} \approx 0.368$$

- Có nghĩa là:
 - Tập huấn luyện (có kích thước n) bao gồm xấp xỉ 63.2% các ví dụ trong D (Lưu ý: một ví dụ thuộc tập D có thể **xuất hiện nhiều lần** trong D_{train})
 - Tập kiểm thử (có kích thước $< n$) bao gồm xấp xỉ 36.8% các ví dụ trong D (Lưu ý: một ví dụ thuộc tập D chỉ có thể **xuất hiện tối đa 1 lần** trong tập D_{test})
- Phù hợp khi ta có tập dữ liệu D có kích thước (rất) nhỏ

Tập tối ưu (Validation set)

- Các ví dụ trong tập kiểm thử **không được phép sử dụng** trong quá trình huấn luyện hệ thống
- Trong một số bài toán học máy, quá trình huấn luyện hệ thống có thể bao gồm 2 giai đoạn:
 - Giai đoạn 1: Huấn luyện hệ thống (Học hàm mục tiêu)
 - Giai đoạn 2: Tìm các giá trị tối ưu cho tham số của hệ thống
- Tập kiểm thử không thể được sử dụng cho mục đích tối ưu (điều chỉnh) tham số
- Chia tập toàn bộ dữ liệu D thành 3 tập con không giao nhau: tập huấn luyện, tập tối ưu, tập kiểm thử
- Tập tối ưu được sử dụng để tìm bộ giá trị tham số tối ưu trong các giải thuật học máy (giá trị tối ưu là giá trị giúp sinh ra hiệu năng cực đại đối với tập tối ưu)

Các tiêu chí đánh giá (1)

- Tính chính xác (Accuracy)
 - Mức độ dự đoán (phân lớp) chính xác của hệ thống (sau khi huấn luyện) đối với các ví dụ kiểm thử (testing examples)
- Tính hiệu quả (Efficient)
 - Chi phí về thời gian và tài nguyên (e.g. bộ nhớ) cần thiết cho việc huấn luyện và kiểm thử hệ thống
- Khả năng xử lý nhiễu (Robustness)
 - Khả năng xử lý (chịu được) của hệ thống đối với các ví dụ nhiễu (lỗi) hoặc thiếu giá trị

Các tiêu chí đánh giá (2)

- Khả năng mở rộng (Scalability)
 - Hiệu năng của hệ thống (e.g. tốc độ học/phân loại) thay đổi như thế nào khi kích thước của tập dữ liệu tăng dần
- Khả năng diễn giải (Interpret-ability)
 - Mức độ dễ hiểu (đối với người sử dụng) của các kết quả và hoạt động của hệ thống
- Mức độ phức tạp (Complexity)
 - Mức độ phức tạp của mô hình hệ thống (hàm mục tiêu) học được

Tính chính xác

- Đối với bài toán phân lớp
 - Giá trị (kết quả) đầu ra của hệ thống là một giá trị định danh

$$Accuracy = \frac{1}{|D_{test}|} \sum_{x \in D_{test}} Identical(o(x), c(x));$$

$$Identical(a, b) = \begin{cases} 1, & \text{if } (a = b) \\ 0, & \text{if otherwise} \end{cases}$$

- x : Một ví dụ trong tập thử nghiệm D_{test}
 - $o(x)$: Giá trị đầu ra (phân lớp) bởi hệ thống đối với ví dụ x
 - $c(x)$: Phân lớp thực sự (đúng) của ví dụ x
- Đối với bài toán hồi quy (dự đoán)

- Giá trị (kết quả) đầu ra của hệ thống là một giá trị số

$$Error = \frac{1}{|D_{test}|} \sum_{x \in D_{test}} Error(x); \quad Error(x) = |d(x) - o(x)|$$

- $o(x)$: Giá trị đầu ra (dự đoán) bởi hệ thống đối với ví dụ x
 - $d(x)$: Giá trị đầu ra thực sự (đúng) của ví dụ x
 - $Accuracy$ là một hàm đảo (inverse function) đối với $Error$

Ma trận nhầm lẫn (1)

- Ma trận nhầm lẫn (Confusion matrix) hay còn được gọi là Contingency table
- Chỉ được sử dụng đối với bài toán phân lớp/loại** (không áp dụng cho bài toán hồi quy)

Bảng 1: Ma trận phân lớp C

Dự đoán $\Rightarrow$	Lớp 1	Lớp 2	...	Lớp c
Lớp 1	$C[1,1]$	$C[1,2]$		$C[1,c]$
Lớp 2	$C[2,1]$	$C[2,2]$		$C[2,c]$
...				
Lớp c	$C[c,1]$	$C[c,2]$		$C[c,c]$

- $C[i,j]$: Tổng số các ví dụ của lớp i được hệ thống phân loại vào lớp j

Ma trận nhầm lẫn (2)

- Trường hợp phân lớp nhị phân, ma trận phân lớp C có kích thước 2×2

Bảng 2: Ma trận phân lớp 2×2

Dự đoán $\Rightarrow$	Dương	Âm
Dương	TP	FN
Âm	FP	TN

- TP**: Tổng số các ví dụ lớp **dương** được phân loại chính xác vào lớp **dương**
- FN**: Tổng số các ví dụ lớp **dương** bị phân loại sai vào lớp **âm**
- TN**: Tổng số các ví dụ lớp **âm** được phân loại chính xác vào lớp **âm**.
- FP**: Tổng số các ví dụ lớp **âm** bị phân loại sai vào lớp **dương**.

Precision, Recall và F_1 (1)

- Khi đánh giá hiệu năng của hệ thống phân lớp nhị phân không cân bằng (có một lớp chiếm đa số so với lớp kia), thì độ đo **accuracy** không phù hợp $\Rightarrow$ sử dụng **precision**, **recall** và F_1

$$precision = \frac{TP}{TP+FP}$$

$$recall = \frac{TP}{TP+FN}$$

$$accuracy = \frac{TP+TN}{TP+FN+TN+FP}$$

$$F_1 = \frac{2 \times precision \times recall}{precision + recall}$$

- F_1 là một trung bình điều hòa (harmonic mean) của các tiêu chí *Precision* và *Recall*
 - F_1 có xu hướng lấy giá trị gần với giá trị nào nhỏ hơn giữa 2 giá trị *Precision* và *Recall*
 - F_1 có giá trị lớn nếu cả 2 giá trị *Precision* và *Recall* đều lớn

- Việc lựa chọn mô hình cần tìm ra sự thỏa hiệp (compromise) phù hợp giữa
 - Mức độ phức tạp của mô hình hệ thống học được
 - Mức độ chính xác về dự đoán của hệ thống đối với tập huấn luyện
- Nguyên lý **Occam's razor**: Một mô hình tốt là một mô hình **đơn giản** đạt **độ chính xác (về phân loại/dự đoán) cao** đối với tập dữ liệu được sử dụng
- Ví dụ:
 - Bộ phân loại sys1: (Rất) đơn giản, và khá (tương đối) phù hợp với tập huấn luyện
 - Bộ phân loại sys2: Khá phức tạp, và phù hợp hoàn hảo với tập huấn luyện

⇒ Bộ phân loại sys1 được ưa thích hơn bộ phân loại sys2

Trước hết xét dãy $\left\{x_n = \left(1 + \frac{1}{n}\right)^{n+1}\right\}$. Ta thấy rằng $\{x_n\}$ là dãy giảm, tức là:

$$\left(1 + \frac{1}{n}\right)^{n+1} > \left(1 + \frac{1}{n+1}\right)^{n+2} \quad (1)$$

Thật vậy, (1) tương đương với:

$$\left(\frac{n+1}{n}\right)^{n+1} > \left(\frac{n+2}{n+1}\right)^{n+2} \quad (2)$$

$$\Leftrightarrow \left(\frac{n+1}{n}\right)^{n+2} > \left(\frac{n+2}{n+1}\right)^{n+2} \cdot \left(\frac{n+1}{n}\right) \Leftrightarrow \left(\frac{(n+1)^2}{n(n+2)}\right)^{n+2} > 1 + \frac{1}{n} \Leftrightarrow$$

Mặt khác, theo BĐT Bernoulli với $h > 0$, $k > 1$, $k \in \mathbb{Z}$, ta có:
 $(1+h)^k > 1+kh \quad (4)$

Thay $h = \frac{1}{n(n+2)}$, $k = n+2$ vào (4) ta thấy BĐT (3) được

chứng minh. Do đó $\{x_n\}$ là dãy giảm.

Hơn nữa dãy $\{x_n\}$ bị chặn dưới, vì $x_n > 0$, $\forall n \in \mathbb{N}^*$. Do đó tồn tại $\lim_{n \rightarrow \infty} x_n$. Mặt khác:

$$\lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n = \lim_{n \rightarrow \infty} \frac{\left(1 + \frac{1}{n}\right)^{n+1}}{1 + \frac{1}{n}} = \frac{\lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^{n+1}}{\lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)} = \lim_{n \rightarrow \infty} x_n$$

Từ đó suy ra tồn tại $\lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n$. Theo Euler giới hạn này được kí hiệu bởi chữ e . Vậy $\lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n = e$.